

中山大学 计算机学院
广州市广州大学城外环东路132号
邮编：510006

《高等数值计算方法》

第一五讲-第一八讲: 线性方程迭代法

(主讲) **汪涛**
wangtao29@mail.sysu.edu.cn
(助理) 屈朝浩
quzh9@mail2.sysu.edu.cn

① **迭代法基本概念**

② 雅可比与高斯-赛德尔迭代

③ 逐次超松弛法(SOR)

④ 共轭梯度法(CG)

考虑线性方程组

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \quad\cdots \qquad\quad \cdots \qquad\quad \cdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases}$$

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}$$

即$AX=b$，其中A为非奇异矩阵，

- 当A为低阶稠密矩阵时，线性方程组用直接法(如高斯消去法和三角分解法)是有效的。

- 但对于由工程技术中产生的大型稀疏矩阵方程组(A的阶数n很大, 但零元素较多)，利用迭代法求解是适合的。在计算机内存和运算两方面，迭代通常都可利用A中有大量零元素的特点。

例6-1 求解线性方程组

$$\begin{cases} 8x_1 - 3x_2 + 2x_3 = 20, \\ 4x_1 + 11x_2 - x_3 = 33, \\ 6x_1 + 3x_2 + 12x_3 = 36. \end{cases}$$

解：方程记为 $\mathrm{Ax}=\mathrm{b}$，即

$$A=\begin{bmatrix}8 & -3 & 2\\ 4 & 11 & -1\\ 6 & 3 & 12\end{bmatrix},\quad x=\begin{bmatrix}x_1\\ x_2\\ x_3\end{bmatrix},\quad b=\begin{bmatrix}20\\ 33\\ 36\end{bmatrix}$$

改写原方程为

$$\begin{cases}x_1=\dfrac{1}{8}(3x_2-2x_3+20),\\ x_2=\dfrac{1}{11}(-4x_1+x_3+33),\\ x_3=\dfrac{1}{12}(-6x_1-3x_2+36).\end{cases}$$

或改写为 $\mathrm{x} = \mathrm{B}_0\mathrm{x} + \mathrm{f}$, 其中

$$B_0 = \begin{bmatrix} 0 & \frac{3}{8} & -\frac{2}{8} \\ -\frac{4}{11} & 0 & \frac{1}{11} \\ -\frac{6}{12} & -\frac{3}{12} & 0 \end{bmatrix}, \quad f = \begin{bmatrix} \frac{20}{8} \\ \frac{33}{11} \\ \frac{36}{12} \end{bmatrix}$$

方程为:

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 & \frac{3}{8} & -\frac{2}{8} \\ -\frac{4}{11} & 0 & \frac{1}{11} \\ -\frac{6}{12} & -\frac{3}{12} & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} + \begin{bmatrix} \frac{20}{8} \\ \frac{33}{11} \\ \frac{36}{12} \end{bmatrix}.$$

构造迭代格式：
$$\begin{cases} x_1^{(k+1)} = (3x_2^{(k)} - 2x_3^{(k)} + 20)/8, \\ x_2^{(k+1)} = (-4x_1^{(k)} + x_3^{(k)} + 33)/11, \\ x_3^{(k+1)} = (-6x_1^{(k)} - 3x_2^{(k)} + 36)/12. \end{cases}$$

即，$\mathrm{x}^{(\mathrm{k}+1)} = \mathrm{B}_0\mathrm{x}^{(\mathrm{k})} + \mathrm{f} \qquad (\mathrm{k} = 0,1,2,\cdots)$

任取初值$\mathrm{x} = (0,0,0)^{\mathrm{T}}$带入，得$\mathrm{x}^{(1)} = (2.5, 3, 3)^{\mathrm{T}}$

反复迭代得，$\mathrm{x}^{(10)}$=(3.000 032, 1.999 838, 0.999 881 3)^{T},

此时，精确解 $\mathrm{x}^* = (3,2,1)^T$

$\left\|\boldsymbol{\varepsilon}^{(10)}\right\|_\infty = 0.000\ 162$,其中 $\boldsymbol{\varepsilon}^{(10)} = \mathbf{x}^{(10)} - \mathbf{x}^*$.

在此例中，迭代法产生的向量序列，逐步逼近此方程组的精确解；

对于任给一线性方程组 $Ax = b$, 由等价变形的方程组

$$\boldsymbol{x = Bx + f}$$

由迭代法产生的向量序列$x^{(k)}$，是否总能逐步逼近此方程组的精确解?

例如：线性方程组

$$\begin{cases} x_1 - 2x_2 = 5 \\ -3x_1 + x_2 = 5 \end{cases}$$

解：改写为 $\mathrm{x}^{(\mathrm{k}+1)}=\mathrm{B}_0\mathrm{x}^{(\mathrm{k})}+\mathrm{f}$ 形式

$$\begin{cases} x_1^{(\mathrm{k}+1)}=2x_2^{(k)}+5 \\ x_2^{(\mathrm{k}+1)}=3x_1^{(k)}+5 \end{cases}$$

任取初值$x=(0,0)^T$带入，得$x^{(1)}=(5,5)^T$，$x^{(2)}=(15,20)^T$

迭代不到精确解$x=(-3,-4)^T$。

迭代法常见形式

一般地， 由$Ax = b$变形得到等价的$x = Bx + f$.

设有唯一解x^*,则

$$x^* = Bx^* + f$$

又设$x^{(0)}$为任取的初始向量，按下述公式构造向量序列

$$x^{(k+1)} = Bx^{(k)} + f \ , \quad k = 0,1,2,\cdots \ (*)$$

其中k表迭代次数。

定义6－1 (1)对于方程组$\mathbf{x}=\mathbf{B}\mathbf{x}+\mathbf{f}$，用公式(*)逐步代入求近似解的方法称为迭代法(一阶定常迭代法).

(2)若$\lim\limits_{k\to\infty}\mathbf{x}^{(k)}$存在(记为$\mathbf{x}^*$)，则称此迭代法收敛,显然$\mathbf{x}^*$是方程组的解,否则迭代法发散.

引进误差向量$\boldsymbol{\varepsilon}^{(k+1)}=\mathbf{x}^{(k+1)}-\mathbf{x}^*$,则由(*)式减去$x^*=Bx^*+f$得

$$\boldsymbol{\varepsilon}^{(k)}=\mathbf{B}\boldsymbol{\varepsilon}^{(k-1)}=\cdots=\mathbf{B}^k\boldsymbol{\varepsilon}^{(0)}.$$

收敛：$\lim\limits_{k\to\infty}\boldsymbol{\varepsilon}^{(k)}=0\Leftrightarrow\lim\limits_{k\to\infty}\mathbf{B}^k=\mathbf{0}.$

要研究$\mathbf{B}$满足什么条件下$\mathbf{B}^k\to\mathbf{0}\,(k\to\infty)$.



定义：设向量序列$\{x^{(k)}\} \subseteq \mathbb{R}^n$, $x^{(k)} = \left(x_1^{(k)}, \cdots, x_n^{(k)}\right)^T \in \mathbb{R}^n$,
如果存在$x = (x_1, \cdots, x_n)^T \in \mathbb{R}^n$, 使 $\lim\limits_{k\to\infty} x_i^{(k)} = x_i \ \forall 1 \le i \le n$,
则称向量序列$\{x^{(k)}\}$收敛于x, 记作$\lim\limits_{k\to\infty} x^{(k)} = x$.

定义：设矩阵序列$A_k = \left(a_{ij}^{(k)}\right)$, 及$A = (a_{ij}) \in \mathbb{R}^{n\times n}$; 如果$n^2$
个数列极限存在且有 $\lim\limits_{k\to\infty} a_{ij}^{(k)} = a_{ij} \ \forall 1 \le i, j \le n$,
则称矩阵序列$\{A_k\}$收敛于A, 记作 $\lim\limits_{k\to\infty} A_k = A$.



定理：$\lim_{k\to\infty} x^{(k)} = x \Leftrightarrow \lim_{k\to\infty} \left\| x^{(k)} - x \right\| = 0$. 这里是考虑任一种向量范数。

定理：$\lim_{k\to\infty} A_k = A \Leftrightarrow \lim_{k\to\infty} \| A_k - A \| = 0$. 这里是考虑任一种算子范数。



定理：$\lim\limits_{k\to\infty} A^{(k)} = 0$ 的充要条件是 $\lim\limits_{k\to\infty} A^{(k)}x = 0\ \forall x \in \mathbb{R}^n$.

定理：$\lim\limits_{k\to\infty} A^{(k)} = 0$ 的充要条件是 $\lim\limits_{k\to\infty} A^{(k)}x = 0\ \forall x \in \mathbb{R}^n$.

证明 必要性显然成立。充分性：取x为第i个单位向量 $e_i = (0,\cdots,0,1,0,\cdots,0)$，则 $\lim\limits_{k\to\infty} A^{(k)}e_i = 0$，从而 $A^{(k)}$ 的第i列元素极限为零，取i=1,2,…,n即有 $\lim\limits_{k\to\infty} A^{(k)} = 0.$

定理：设$B \in \mathbb{R}^{n\times n}$, 下面三个命题是等价的.

① $\lim\limits_{k\to\infty} B^k = \lim\limits_{k\to\infty} \underbrace{B\cdots B}_{k} = 0;$

② $\rho(B) < 1;$

③ 至少存在一种从属的矩阵范数，使得$\|B\|_\epsilon < 1.$

这里$\|B\|_\epsilon \le \rho(B) + \epsilon.$

证明：(1)->(2) 反证法，假定B有一个特征值λ，满足$|\lambda| \geq 1$, 则存在$x \neq 0$, 使得$Bx = \lambda x$. 由此可得$\|B^k x\| = |\lambda|^k \|x\|$, 当$k \to \infty$时，$\{B^k x\}$不收敛于零向量。由充要条件可知, (1) 不成立；从而得 $|\lambda| < 1$, (2)成立。

(2)->(3) 对任意$\epsilon > 0$, 存在从属范数$\|\cdot\|_\epsilon$, 使得$\|B\|_\epsilon \leq \rho(B) + \epsilon$, 由(2)知 $\rho(B) < 1$, 取$\epsilon = \frac{1-\rho(B)}{2}$, 可使$\|B\|_\epsilon \leq \frac{1+\rho(B)}{2} < 1$, (3)成立。

(3)->(1) 由(3)给出的矩阵范数$\|B\|_\epsilon < 1$且$\left\|B^k\right\|_\epsilon \leq \|B\|_\epsilon^k$可得当$k \to \infty$时$\left\|B^k\right\|_\epsilon \to 0$。从而有$\lim_{k\to\infty} B^k = 0.$

定理：设$B \in \mathbb{R}^{n\times n}$, $\|\cdot\|$为任一种矩阵范数，则

$$\lim_{k\to\infty}\left\|B^k\right\|^{\frac{1}{k}} = \rho(B)$$

证明：对一切k都有 $\rho(B)=\left(\rho\left(B^k\right)\right)^{1/k}\leq\left\|B^k\right\|^{1/k}$,

对任意$\epsilon>0$, 记 $B_\epsilon=(\rho(B)+\epsilon)^{-1}B$,

显然，$\rho(B_\epsilon)<1$, 则$\lim\limits_{k\to\infty}B_\epsilon^k=0$;

则存在$N(\epsilon)$, 使得当$k>N(\epsilon)$时 $\left\|B_\epsilon^k\right\|=\frac{\|B^k\|}{(\rho(B)+\epsilon)^k}<1$,

即, 对所有$k>N(\epsilon)$, 有$\rho(B)\leq\left\|B^k\right\|^{\frac{1}{k}}\leq\rho(B)+\epsilon$.

令$\epsilon\to0$, 可得定理结论。

例：判定以下矩阵B是否满足 $\lim_{k\to\infty} B^k = 0$？

$$B_1 = \begin{bmatrix} 0.7 & 1.0 \\ 0.0 & 0.3 \end{bmatrix}, \qquad B_2 = \begin{bmatrix} 0.7 & 1.0 \\ -1.0 & 0.3 \end{bmatrix}$$



基本迭代

考虑线性方程组

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \cdots \quad \cdots \quad \cdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases}$$

就是 $\mathbf{Ax} = \mathbf{b}$ 进行矩阵分裂 $\mathbf{A} = \mathbf{M} - \mathbf{N}$

且M为可选择的非奇异矩阵，且使得$\mathbf{Mx} = \mathbf{d}$容易求解于是

$$\mathbf{Ax} = \mathbf{b} \Leftrightarrow \mathbf{x} = \mathbf{M}^{-1}\mathbf{Nx} + \mathbf{M}^{-1}\mathbf{b}$$

可得一阶定常迭代法

$$\begin{cases} \text{取初始向量}\mathbf{x}^{(0)}, \\ \mathbf{x}^{(k+1)} = \mathbf{Bx}^{(k)} + \mathbf{f}, k = 0,1,\cdots, \end{cases}$$

其中$\mathbf{B} = \mathbf{M}^{-1}\mathbf{N} = \mathbf{M}^{-1}(\mathbf{M} - \mathbf{A}) = \mathbf{I} - \mathbf{M}^{-1}\mathbf{A}, \mathbf{f} = \mathbf{M}^{-1}\mathbf{b}.$

定理：给定线性方程组$Ax = b$, 以及一阶定常迭代法

$$x^{(k+1)} = Bx^{(k)} + f,$$

对任取的初值$x^{(0)}$, 此迭代法收敛 $\Leftrightarrow$ 谱半径 $\rho(B) < 1.$

证明：**充分性**. 设$\rho(B)<1$, 知$Hx=(I-B)x=f$有唯一解x^*, 则$x^*=Bx^*+f$. 误差 $\epsilon^{(k)}=x^{(k)}-x^*=B^k\epsilon^{(0)}$, $\epsilon^{(0)}=x^{(0)}-x^*$; 由$\rho(B)<1$, 知$\lim\limits_{k\to\infty}B^k=0$. 可得 $\lim\limits_{k\to\infty}\epsilon^{(k)}=0$, 即$\lim\limits_{k\to\infty}x^{(k)}=x^*$.

必要性. 设对任意$x^{(0)}$有 $\lim\limits_{k\to\infty}x^{(k)}=x^*$, 这里$x^{(k+1)}=Bx^{(k)}+f$. 显然, 极限$x^*$是线性方程组$x=Bx+f$的解, 且对任意$x^{(0)}$有 $\epsilon^{(k)}=x^{(k)}-x^*=B^k\epsilon^{(0)}\to 0\ (k\to\infty)$. 由充要条件可知$\lim\limits_{k\to\infty}B^k=0$, 由等价定理可知 $\rho(B)<1$.

例：给定迭代式 $x^{(k+1)} = Bx^{(k)} + f$, 这里

$$B = \begin{bmatrix} 0 & 0.6 \\ 2 & 0 \end{bmatrix}, \quad f = \begin{bmatrix} 0.5 \\ -0.5 \end{bmatrix}, \quad x^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

判定向量序列$\{x^{(k)} \in \mathbb{R}^2, k \geq 0\}$的收敛性。



定理：设有线性方程组

$$x = Bx + f, \qquad B \in \mathbb{R}^{n\times n}$$

以及一阶定常迭代法

$$x^{(k+1)} = Bx^{(k)} + f.$$

如果有B的某种算子范数$\|B\| = q < 1$, 那么

(1) 迭代法收敛, 即对任取$x^{(0)}$有

$$\lim_{k\to\infty} x^{(k)} = x^*, \quad \text{且} x^* = Bx^* + f;$$

(2) $\left\|x^* - x^{(k)}\right\| \le q^k \cdot \left\|x^* - x^{(0)}\right\|;$

(3) $\left\|x^* - x^{(k)}\right\| \le \frac{q}{1-q} \cdot \left\|x^{(k)} - x^{(k-1)}\right\|;$

(4) $\left\|x^* - x^{(k)}\right\| \le \frac{q^k}{1-q} \cdot \left\|x^{(1)} - x^{(0)}\right\|;$

证明：数学分析/级数

定义:

平均收敛速度

$$R_k(B) = -\ln\left(\left\|B^k\right\|^{\frac{1}{k}}\right)$$

渐近收敛速度

$$R(B) = -\ln(\rho(B))$$

① 迭代法基本概念

② 雅可比与高斯-赛德尔迭代

③ 逐次超松弛法(SOR)

④ 共轭梯度法(CG)

记矩阵 $A=D-L-U$，其中

$$A=\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} \qquad D=\begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix}$$

$$-L=\begin{bmatrix} 0 & & & \\ a_{21} & 0 & & \\ \vdots & \vdots & \ddots & \\ a_{n1} & a_{n2} & \cdots & 0 \end{bmatrix} \qquad -U=\begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ & 0 & \cdots & a_{2n} \\ & & \ddots & \vdots \\ & & & 0 \end{bmatrix}$$

雅可比迭代

采用矩阵分裂记号

$$A = D - L - U,$$

其中

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix}, L = \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix},$$

$$U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ & 0 & \ddots & \vdots \\ & & \ddots & -a_{n-1,n} \\ & & & 0 \end{bmatrix}.$$

$$\begin{aligned} Dx^{(k+1)} &= (L+U)x^{(k)} + b \\ &= Lx^{(k)} + Ux^{(k)} + b. \end{aligned}$$

雅可比迭代法的矩阵表示形式为

$$x^{(k+1)} = D^{-1}(L+U)x^{(k)} + D^{-1}b \overset{\Delta}{=} B_J x^{(k)} + f$$

$$\begin{cases} x_1 = \dfrac{1}{a_{11}}(b_1 - a_{12}x_2 - \cdots - a_{1n}x_n) \\ \cdots \quad \cdots \quad \cdots \\ x_i = \dfrac{1}{a_{ii}}(b_i - \sum_{j=1}^{i-1} a_{ij}x_j - \sum_{j=i+1}^{n} a_{ij}x_j) \\ \cdots \quad \cdots \quad \cdots \\ x_n = \dfrac{1}{a_{nn}}(b_n - a_{n1}x_1 - \cdots - a_{n,n-1}x_{n-1}) \end{cases}$$

可以得到计算公式（雅可比迭代法），对$k = 0,1,\cdots$

$$\begin{cases} x^{(0)} = (x_1^{(0)}, \cdots, x_n^{(0)})^T, \\ x_i^{(k+1)} = (b_i - \sum_{\substack{j=1 \\ j\neq i}}^{n} a_{ij}x_j^{(k)})/a_{ii}, \quad (i = 1, \cdots, n) \end{cases}$$



高斯 赛德尔迭代

$$\begin{cases} x^{(0)} = (x_1^{(0)}, \cdots, x_n^{(0)})^T, \\ x_i^{(k+1)} = (b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^{n} a_{ij} x_j^{(k)}) / a_{ii}, \quad (i = 1, \cdots, n) \end{cases}$$

称为高斯赛德尔迭代法。

采用矩阵A的分裂记号，迭代法等价于

$$\mathbf{D}\mathbf{x}^{(k+1)} = \mathbf{L}\mathbf{x}^{(k+1)} + \mathbf{U}\mathbf{x}^{(k)} + \mathbf{b}$$

高斯赛德尔迭代法的矩阵表示形式为

$$\mathbf{x}^{(k+1)} = (\mathbf{D}-\mathbf{L})^{-1}\mathbf{U}\mathbf{x}^{(k)} + (\mathbf{D}-\mathbf{L})^{-1}\mathbf{b} \overset{\Delta}{=} \mathbf{B}_G\mathbf{x}^{(k)} + \mathbf{f}$$

例：用迭代法求线性方程组

$$\begin{cases} 8x_1 - 3x_2 + 2x_3 = 20, \\ 4x_1 + 11x_2 - x_3 = 33, \\ 6x_1 + 3x_2 + 12x_3 = 36. \end{cases}$$

取初值$x^{(0)} = (0,0,0)^T$.

$$A=\begin{bmatrix}8&-3&2\\4&11&-1\\6&3&12\end{bmatrix}=\underbrace{\begin{bmatrix}8&&\\&11&\\&&12\end{bmatrix}}_{D}-\underbrace{\begin{bmatrix}&&\\-4&&\\-6&-3&\end{bmatrix}}_{L}-\underbrace{\begin{bmatrix}&3&-2\\&&1\\&&\end{bmatrix}}_{U}$$

雅可比迭代： $x^{(k+1)}=\boldsymbol{D^{-1}}(\boldsymbol{L}+\boldsymbol{U})x^{(k)}+\boldsymbol{D^{-1}b}=\boldsymbol{B}x^{(k)}+\boldsymbol{f}$;

$$\boldsymbol{B}=\begin{bmatrix}8&&\\&11&\\&&12\end{bmatrix}^{-1}\left(\begin{bmatrix}&&\\-4&&\\-6&-3&\end{bmatrix}+\begin{bmatrix}&3&-2\\&&1\\&&\end{bmatrix}\right)=\begin{bmatrix}&3/8&-1/4\\-4/11&&1/11\\-1/2&-1/4&\end{bmatrix};$$

$$\boldsymbol{f}=\begin{bmatrix}8&&\\&11&\\&&12\end{bmatrix}^{-1}\begin{bmatrix}20\\33\\36\end{bmatrix}=\begin{bmatrix}5/2\\3\\3\end{bmatrix};\quad \boldsymbol{x^{(0)}}=\begin{bmatrix}0\\0\\0\end{bmatrix};$$

$$\boldsymbol{x^{(1)}}=\begin{bmatrix}2.5000\\3.0000\\3.0000\end{bmatrix},\ \boldsymbol{x^{(2)}}=\begin{bmatrix}2.8550\\2.3636\\1.0000\end{bmatrix},\ \boldsymbol{x^{(3)}}=\begin{bmatrix}3.1364\\2.0455\\0.9716\end{bmatrix};$$

$$\boldsymbol{x^{(4)}}=\begin{bmatrix}3.0241\\1.9478\\0.9205\end{bmatrix},\ \boldsymbol{x^{(5)}}=\begin{bmatrix}3.0003\\1.9840\\1.0010\end{bmatrix},\ \boldsymbol{x^{(6)}}=\begin{bmatrix}2.9938\\2.0000\\1.0038\end{bmatrix};$$

$$A=\begin{bmatrix}8&-3&2\\4&11&-1\\6&3&12\end{bmatrix}=\underset{D}{\begin{bmatrix}8&&\\&11&\\&&12\end{bmatrix}}-\underset{L}{\begin{bmatrix}&&\\-4&&\\-6&-3&\end{bmatrix}}-\underset{U}{\begin{bmatrix}&3&-2\\&&1\\&&\end{bmatrix}}$$

高斯-塞德尔迭代： $x^{(k+1)}=(\boldsymbol{D}-\boldsymbol{L})^{-1}\boldsymbol{U}x^{(k)}+(\boldsymbol{D}-\boldsymbol{L})^{-1}\boldsymbol{b}=\boldsymbol{B}x^{(k)}+\boldsymbol{f}$;

$$\boldsymbol{B}=\left(\begin{bmatrix}8&&\\&11&\\&&12\end{bmatrix}-\begin{bmatrix}&&\\-4&&\\-6&-3&\end{bmatrix}\right)^{-1}\begin{bmatrix}&3&-2\\&&1\\&&\end{bmatrix}=\begin{bmatrix}&0.3750&-0.2500\\&-0.1364&0.1818\\&-0.1534&0.0795\end{bmatrix};$$

$$\boldsymbol{f}=\left(\begin{bmatrix}8&&\\&11&\\&&12\end{bmatrix}-\begin{bmatrix}&&\\-4&&\\-6&-3&\end{bmatrix}\right)^{-1}\begin{bmatrix}20\\33\\36\end{bmatrix}=\begin{bmatrix}2.5000\\2.0909\\1.2273\end{bmatrix};\quad \boldsymbol{x}^{(0)}=\begin{bmatrix}0\\0\\0\end{bmatrix};$$

$$\boldsymbol{x}^{(1)}=\begin{bmatrix}2.5000\\2.0909\\1.2273\end{bmatrix},\ \boldsymbol{x}^{(2)}=\begin{bmatrix}2.9773\\2.0289\\1.0041\end{bmatrix},\ \boldsymbol{x}^{(3)}=\begin{bmatrix}3.0098\\1.9968\\0.9959\end{bmatrix};$$

$$\boldsymbol{x}^{(4)}=\begin{bmatrix}2.9998\\1.9997\\1.0002\end{bmatrix},\ \boldsymbol{x}^{(5)}=\begin{bmatrix}2.9998\\2.0001\\1.0001\end{bmatrix},\ \boldsymbol{x}^{(6)}=\begin{bmatrix}3.0000\\2.0000\\1.0000\end{bmatrix};$$

例：用迭代法求线性方程组

$$\begin{cases} 10x_1 - x_2 - 2x_3 = 7.2 \\ -x_1 + 10x_2 - 2x_3 = 8.3 \\ -x_1 - x_2 + 5x_3 = 4.2 \end{cases}$$

$$\begin{cases} x_1^{(k+1)} = \dfrac{1}{10}(\quad x_2^{(k)} + 2x_3^{(k)} + 7.2) \\ x_2^{(k+1)} = \dfrac{1}{10}(x_1^{(k)} \quad + 2x_3^{(k)} + 8.3) \\ x_3^{(k+1)} = \dfrac{1}{5}(x_1^{(k)} + x_2^{(k)} \quad + 4.2) \end{cases}$$

雅可比迭代法

取

$x^{(0)} = (0,0,0)^T$

计算如下

k	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$
1	0.72	0.83	0.84
2	0.971	1.07	1.15
…	…	…	…
11	1.099993	1.199993	1.299991
12	1.099998	1.199998	1.299997

$$\begin{cases} x_1^{(k+1)} = \dfrac{1}{10}(\quad x_2^{(k)} + 2x_3^{(k)} + 7.2) \\ x_2^{(k+1)} = \dfrac{1}{10}(x_1^{(k+1)} \quad + 2x_3^{(k)} + 8.3) \\ x_3^{(k+1)} = \dfrac{1}{5}(x_1^{(k+1)} + x_2^{(k+1)} \quad + 4.2) \end{cases}$$

高斯-塞德尔迭代法

取 $x^{(0)}=(0,0,0)^T$ 计算如下:

k	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$
1	0.72	0.902	1.1644
…	…	…	…
8	1.099998	1.199999	1.3

定理：设$Ax = b$，其中$A = D - L - U$为非奇异矩阵，且对角矩阵D也非奇异。则

(1) 雅可比迭代法收敛的充要条件是

$$\rho(J) < 1, \qquad J \doteq D^{-1}(L + U).$$

(2) 高斯-塞德尔迭代法收敛的充要条件是

$$\rho(G) < 1, \qquad G \doteq (D - L)^{-1}U.$$

定义：（对角占优矩阵）设 $A=(a_{ij})_{n\times n}$，

(1) 如果

$$|a_{ii}|>\Sigma_{j=1,j\neq i}^{n}|a_{ij}|,\qquad 1\leq i\leq n,$$

则称A是**严格对角占优**矩阵。

(2) 如果

$$|a_{ii}|\geq\Sigma_{j=1,j\neq i}^{n}|a_{ij}|,\qquad 1\leq i\leq n,$$

且上式**至少有一个不等式严格**成立。则称A是**弱对角占优**矩阵。

定义：（可约与不可约矩阵）设 $A=(a_{ij})_{n\times n}, n\geq 2,$

- 如果存在置换矩阵P使得

$$P^TAP=\begin{bmatrix}A_{11} & A_{12}\\ 0 & A_{22}\end{bmatrix},$$

其中A_{11} 为r阶方阵， A_{22}为$(n-r)$阶方阵$(1\leq r\leq n)$，则称A为可约矩阵。

- 否则，如果不存在这样的置换矩阵P, 则称A为不可约矩阵。



定理：（对角占有定理）如果 $A=(a_{ij})_{n\times n}$ 为**严格对角占优**矩阵或者**不可约弱对角占优**矩阵，则A为非奇异矩阵。

证明：（严格对角占优）

采用反证法，如果 $\det(A)=0$，则 $Ax=0$ 有非零解，记为 $x=(x_1,x_2,\cdots,x_n)^T$，则

$$|x_k|=\max_{1\le i\le n}|x_i|\neq 0.$$

由齐次方程组第 k 个方程

$$\sum_{j=1}^{n}a_{kj}x_j=0,$$

则有

证明：（严格对角占优）

$$|a_{kk}x_k| = \left|\sum_{\substack{j=1\\ j\neq k}}^{n} a_{kj}x_j\right| \le \sum_{\substack{j=1\\ j\neq k}}^{n} |a_{kj}||x_j| \le |x_k|\sum_{\substack{j=1\\ j\neq k}}^{n} |a_{kj}|,$$

即

$$|a_{kk}| \le \sum_{\substack{j=1\\ j\neq k}}^{n} |a_{kj}|,$$

与假设矛盾，故 $\det(A) \neq 0.$

定理：设 $Ax = b$, 如果

(1) A为严格对角占优矩阵，则解$Ax = b$的雅可比迭代法，高斯-塞德尔迭代法都收敛。

(2) A为弱对角占优矩阵，且不可约矩阵；则解$Ax = b$的雅可比方法，高斯-塞德尔迭代法都收敛。

证明：只证 (1) 中高斯-塞德尔迭代法的收敛性，其他同理。

由设可知，$a_{ii} \neq 0 (i = 1, \cdots, n)$，解 $Ax = b$的高斯-塞德尔迭代法的迭代矩阵为

$$G = (D - L)^{-1} U \ (A = D - L - U)$$

下面考查 G的特征值情况.

$$\det(\lambda I - G) = \det(\lambda I - (D - L)^{-1} U)$$

$$= \det((D - L)^{-1}) \cdot \det(\lambda (D - L) - U).$$

证明：只证 (1) 中高斯-塞德尔迭代法的收敛性，其他同理。

由于 $\det((D-L)^{-1}) \neq 0$, 于是 G 特征值即为

$$\det(\lambda(D-L)-U)=0$$

之根. 记

$$C \equiv \lambda(D-L)-U = \begin{pmatrix} \lambda a_{11} & a_{12} & \cdots & a_{1n} \\ \lambda a_{21} & \lambda a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ \lambda a_{n1} & \lambda a_{n2} & \cdots & \lambda a_{nn} \end{pmatrix},$$

证明：只证 (1) 中高斯-塞德尔迭代法的收敛性，其他同理。

下面证明，当 $|\lambda| \geq 1$ 时，$\det(C) \neq 0$，即 G 的特征值均满足 $|\lambda| < 1$，由基本定理，则有高斯–塞德尔迭代法收敛.

事实上，当 $|\lambda| \geq 1$ 时，由 A 为严格对角占优阵，有

$$|c_{ii}| = |\lambda a_{ii}| > |\lambda| \cdot \left(\sum_{j=1}^{i-1} |a_{ij}| + \sum_{j=i+1}^{n} |a_{ij}| \right)$$

$$\geq \sum_{j=1}^{i-1} |\lambda a_{ij}| + \sum_{j=i+1}^{n} |a_{ij}| = \sum_{\substack{j=1 \\ j \neq i}}^{n} |c_{ij}|$$

$$(i = 1, 2, \cdots, n).$$

这说明，当 $|\lambda| \geq 1$ 时，矩阵 C 为严格对角占优阵，再由对角占优定理有 $\det(C) \neq 0$.



定理：设矩阵A对称，且对角元$a_{ii} > 0, 1 \le i \le n$, 则

(1) 解线性方程组 $Ax = b$ 的雅可比迭代法 **收敛**的 **充分必要**条件是 A 及 $2D - A$ 均为正定矩阵，其中$D = diag(a_{11}, a_{22}, \cdots, a_{nn})$。

(2) 解线性方程组 $Ax = b$ 的高斯-塞德尔迭代法 **收敛**的 **充分**条件是 A 正定。

例：求解下列线性方程组时，判定雅可比迭代法 和 高斯-塞德尔迭代法的收敛性。

$$\begin{bmatrix} 1 & -0.5 & 0 \\ -0.5 & 1 & -0.5 \\ 0 & -0.5 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0.7 \\ 0.8 \\ 0.9 \end{bmatrix}$$

解:

$$B_J=\begin{bmatrix}0 & 0.5 & 0\\ 0.5 & 0 & 0.5\\ 0 & 0.5 & 0\end{bmatrix}$$

$$\det(\lambda I-B_J)=\begin{vmatrix}\lambda & -0.5 & 0\\ -0.5 & \lambda & -0.5\\ 0 & -0.5 & \lambda\end{vmatrix}=\lambda(\lambda^2-0.5)$$

$$\rho(B_J)=\sqrt{0.5}<1$$

故Jacobi 迭代法收敛。

例：在线性方程组 $Ax = b$ 中

$$A = \begin{bmatrix} 1 & a & a \\ a & 1 & a \\ a & a & 1 \end{bmatrix}$$

证明：

- 当$a \in \left(-\frac{1}{2}, 1\right)$时，高斯-塞德尔迭代法收敛；
- 雅可比迭代法只在$a \in \left(-\frac{1}{2}, \frac{1}{2}\right)$时才收敛；

证明：计算特征多项式

① 迭代法基本概念

② 雅可比与高斯-赛德尔迭代

③ 逐次超松弛法(SOR)

④ 共轭梯度法(CG)

例：已知线性方程组和初值

$$\begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 24 \\ 30 \\ -24 \end{bmatrix}, \qquad x^{(0)} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}.$$

利用下列两组迭代式求解此方程组：

$$(I) \quad \begin{cases} x_1^{(k+1)} = -0.75x_2^{(k)} + 6, \\ x_2^{(k+1)} = -0.75x_1^{(k+1)} + 0.25x_3^{(k)} + 7.5, \\ x_3^{(k+1)} = 0.25x_2^{(k+1)} - 6. \end{cases}$$

$$(II) \quad \begin{cases} x_1^{(k+1)} = -0.25x_1^{(k)} - 0.9375x_2^{(k)} + 7.5, \\ x_2^{(k+1)} = -0.9375x_1^{(k+1)} - 0.25x_2^{(k)} + 0.3125x_3^{(k)} + 9.75, \\ x_3^{(k+1)} = 0.3125x_2^{(k+1)} - 0.25x_3^{(k)} - 7.5. \end{cases}$$

k	(I)			(II)		
0	1.0000000	1.0000000	1.0000000	1.0000000	1.0000000	1.0000000
1	5.2500000	3.1825000	-5.0468750	6.3125000	3.9195313	-6.6501465
2	3.1406250	3.8828125	-5.0292969	2.6223145	3.9585266	-4.6004238
3	3.0878906	3.9267587	-5.0183105	3.1333027	4.0402646	-5.0966863
4	3.0549316	3.9542236	-5.0114410	2.9570512	4.0074838	-4.9734897
5	3.0343323	3.9713898	-5.0071526	3.0037211	4.0029250	-5.0057135
6	3.0214577	3.9821186	-5.0044703	2.9963276	4.0009262	-4.9982822
7	**3.0134110**	**3.9888241**	**-5.0027940**	**3.0000498**	**4.0002586**	**-5.0003486**

给定线性方程组: $\boldsymbol{Ax} = \boldsymbol{b}$, 其中，$A = (a_{ij})_{n\times n}$非奇异，且$a_{ii} \neq 0 \forall i.$

如果已经得到:

- 第k次迭代量 $x^{(k)}$; 以及
- 第$(k+1)$次迭代量 $x^{(k+1)}$的前$(i-1)$个分量$x_1^{(k+1)}, \cdots, x_{i-1}^{(k+1)}$;

计算 $x_i^{(k+1)}$，先用**高斯-塞德尔**迭代法得到

$$\tilde{x}_i^{(k+1)} = \left\{ b_i - \Sigma_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \Sigma_{j=i+1}^{n} a_{ij} x_j^{(k)} \right\} / a_{ii}$$

$$\boldsymbol{x_i^{(k+1)} = (1-\omega) x_i^{(k)} + \omega \tilde{x}_i^{(k+1)}}.$$

（I）$\omega = 1$			(II) $\omega = 1.25$		
3.0134110	**3.9888241**	**-5.0027940**	**3.0000498**	**4.0002586**	**-5.0003486**

SOR迭代法的计算公式:对 k=0, 1, …

$$\begin{cases} x_i^{(k+1)} = (1-\omega)x_i^{(k)} + \dfrac{\omega}{a_{ii}}\left[b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^{n} a_{ij}x_j^{(k)}\right] & (i = 1,2,\cdots,n) \\ X^{(0)} = (x_1^{(0)}, x_2^{(0)}, \cdots, x_n^{(0)})^T & (k = 1,2,\cdots) \end{cases}$$

ω: 松弛因子

$$A = M - N = \frac{1}{\omega}(D - \omega L) - \frac{1}{\omega}\{(1-\omega)D + \omega U\}.$$

采用矩阵A的分裂记号, 化为

$$Dx^{(k+1)} = Dx^{(k)} + \omega(b + Lx^{(k+1)} + Ux^{(k)} - Dx^{(k)})$$

SOR迭代法的矩阵表示形式为 L_ω

$$x^{(k+1)} = (D - \omega L)^{-1}\{(1-\omega)D + \omega U\}x^{(k)} + \omega(D - \omega L)^{-1}b\ .$$

说明: 1) ω=1,即为GS（高斯-塞德尔迭代法）；

2) ω>1，称为超松驰法；

ω<1，称为低松驰法；

3) SOR方法每迭代一次主要运算量是计算一次矩阵与向量的乘法。

例6-3 用SOR迭代法解线性代数方程组

$$\begin{bmatrix} -4 & 1 & 1 & 1 \\ 1 & -4 & 1 & 1 \\ 1 & 1 & -4 & 1 \\ 1 & 1 & 1 & -4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} \mathbf{1} \\ \mathbf{1} \\ \mathbf{1} \\ \mathbf{1} \end{bmatrix}$$

解: 取$X^{(0)}=0$，迭代公式为

$$\begin{cases} x_1^{(k+1)} = x_1^{(k)} - \omega(1+4x_1^{(k)} - x_2^{(k)} - x_3^{(k)} - x_4^{(k)})/4 \\ x_2^{(k+1)} = x_2^{(k)} - \omega(1-x_1^{(k+1)} + 4x_2^{(k)} - x_3^{(k)} - x_4^{(k)})/4 \\ x_3^{(k+1)} = x_3^{(k)} - \omega(1-x_1^{(k+1)} - x_2^{(k+1)} + 4x_3^{(k)} - x_4^{(k)})/4 \\ x_4^{(k+1)} = x_4^{(k)} - \omega(1-x_1^{(k+1)} - x_2^{(k+1)} - x_3^{(k+1)} + 4x_4^{(k)})/4 \end{cases}$$

取$\omega=1.3$,第11次迭代结果为

$$x^{(11)} = (-0.999\ 996\ 46, -1.000\ 003\ 10, -0.999\ 999\ 53,$$
$$-0.999\ 999\ 12)^T$$

此时，$\left\|\varepsilon^{(11)}\right\|_2 = 0.46\times10^{-5}$

注：迭代法求解线性方程组在计算机实现时可用

$$\left\|\mathbf{x}^{(k+1)}-\mathbf{x}^{(k)}\right\|_{\infty}=\max_{1\le i\le n}\left|x_i^{(k+1)}-x_i^{(k)}\right|<\varepsilon$$

控制迭代终止，或用$\left\|\mathbf{r}^{(k)}\right\|_{\infty}=\left\|\mathbf{b}-\mathbf{A}\mathbf{x}^{(k)}\right\|_{\infty}<\varepsilon$ 控制迭代终止。



定理: (SOR迭代法收敛的必要条件) 设解线性方程组$Ax = b$的SOR迭代法收敛，则$0 < \omega < 2$.



证明: 由设SOR迭代法收敛，则$\rho(L_\omega) < 1$, 设L_ω的特征值为$\lambda_1, \lambda_2, \cdots, \lambda_n$, 进而

$$|\det(L_\omega)| = |\lambda_1 \lambda_2 \cdots \lambda_n| \leq [\rho(L_\omega)]^n,$$

或

$$[\det(L_\omega)]^{1/n} \leq \rho(L_\omega) < 1.$$

另一方面,

$$\begin{aligned} \det(L_\omega) &= \det[(D - \omega L)^{-1}] \cdot \det[(1-\omega)D + \omega U] \\ &= |1 - \omega|^n, \end{aligned}$$

从而

$$|\det(L_\omega)|^{1/n} = |1 - \omega| \leq \rho(L_\omega) < 1,$$

得

$$0 < \omega < 2.$$

定理: 设 $Ax = b$, 如果

(1) A为对称正定矩阵，$A = D - L - U$;

(2) $0 < \omega < 2$.

则解$Ax = b$的SOR迭代法收敛。

证明: 在上述假定下，如果能证明$|\lambda| < 1$, 则定理得证。

事实上，设y为对应于λ的L_ω的特征向量，即

$$L_\omega y = \lambda y, \qquad y = (y_1, \cdots, y_n)^T \neq 0,$$
$$(D - \omega L)^{-1}[(1-\omega)D + \omega U]y = \lambda y,$$

亦即

$$[(1-\omega)D + \omega U]y = \lambda(D - \omega L)y.$$

为了找出λ的表达式，考虑数量积

$$([(1-\omega)D + \omega U]y, y) = \lambda((D - \omega L)y, y)$$

则

$$\lambda = \frac{(Dy, y) - \omega(Dy, y) + \omega(Uy, y)}{(Dy, y) - \omega(Ly, y)}$$

显然 $(Dy,y)=\Sigma_{i=1}^{n}a_{ii}|y_i|^2=\sigma>0.$
记 $-(Ly,y)=\alpha+i\beta,$

由于$A=A^T$, 所以$U=L^T$, 故

$$-(Uy,y)=-(y,Ly)=-\overline{(Ly,y)}=\alpha-i\beta,$$
$$0<(Ay,y)=\big((D-L-U)y,y\big)=\sigma+2\alpha,$$

所以

$$\lambda=\frac{(\sigma-\omega\sigma-\alpha\omega)+i\omega\beta}{(\sigma+\alpha\omega)+i\omega\beta},$$

从而

$$|\lambda|^2=\frac{(\sigma-\omega\sigma-\alpha\omega)^2+\omega^2\beta^2}{(\sigma+\alpha\omega)^2+\omega^2\beta^2}$$



当$0 < \omega < 2$时，我们有

$$(\sigma - \omega\sigma - \alpha\omega)^2 - (\sigma + \alpha\omega)^2$$
$$= \omega\sigma(\sigma + 2\alpha)(\omega - 2) < 0,$$

即L_ω的任一特征值满足$|\lambda| < 1$, 故SOR迭代法收敛。

证毕

定理: 设 $Ax = b$, 如果

(1) A为严格对角占优矩阵(或A为弱对角占优不可约);

(2) $0 < \omega \leq 1$.

则解$Ax = b$的SOR迭代法收敛。

分块迭代：

即一块或一组未知数同时被改进。

设 $Ax=b$，其中 $A\in \mathbf{R}^{n\times n}$ 为大型稀疏矩阵且将 A 分块为三部分 $A=D-L-U$，其中

$$A=\begin{pmatrix} A_{11} & A_{12} & \cdots & A_{1q} \\ A_{21} & A_{22} & \cdots & A_{2q} \\ \vdots & \vdots & & \vdots \\ A_{q1} & A_{q2} & \cdots & A_{qq} \end{pmatrix},\quad D=\begin{pmatrix} A_{11} & & & \\ & A_{22} & & \\ & & \ddots & \\ & & & A_{qq} \end{pmatrix},$$

$$L=\begin{pmatrix} 0 & & & \\ -A_{21} & 0 & & \\ \vdots & \vdots & \ddots & \\ -A_{q1} & -A_{q2} & \cdots & 0 \end{pmatrix}, \quad U=\begin{pmatrix} 0 & -A_{12} & \cdots & -A_{1q} \\ & 0 & \cdots & -A_{2q} \\ & & \ddots & \vdots \\ & & & 0 \end{pmatrix}.$$

且 $A_{ii}\,(i=1,2,\cdots,q)$ 为 $n_i \times n_i$非奇异矩阵， $\sum_{i=1}^{q} n_i = n.$

珑对 x及 b同样分块

$$x=\begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_q \end{pmatrix}, \qquad b=\begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_q \end{pmatrix},$$

其中， $x_i \in \mathbf{R}^{n_i}, b_i \in \mathbf{R}^{n_i}$.

(1) 块雅可比迭代法(BJ)

选取分裂阵M为A的对角块部分，即选

$$\begin{cases} M=D\ (\text{块对角阵}) \\ A=M-N. \end{cases}$$

于是，得到块雅可比迭代法

$$x^{(k+1)}=Bx^{(k)}+f \qquad (4.1)$$

其中迭代矩阵 $B=I-D^{-1}A=D^{-1}(L+U)\equiv J,\ f=D^{-1}b.$

或

$$Dx^{(k+1)}=(L+U)x^{(k)}+b.$$

由分块矩阵乘法，得到块雅可比迭代法的具体形式

$$A_{ii}x_i^{(k+1)} = b_i - \sum_{\substack{j=1 \\ j\neq i}}^{q} A_{ij}x_j^{(k)} \quad (i=1,2,\cdots,q), \qquad (4.1)$$

其中

$$x^{(k)} = \begin{pmatrix} x_1^{(k)} \\ x_2^{(k)} \\ \vdots \\ x_q^{(k)} \end{pmatrix}, \quad x_i^{(k)} \in \mathbf{R}^{n_i}.$$

这说明，块雅可比迭代法每迭代一步，从 $x^{(k)} \to x^{(k+1)}$

需要求解 q 个低阶方程组

$$\begin{cases} A_{ii}x_i^{(k)} = g_i \\ (i=1,2,\cdots,q), \text{ 其中 } g_i \text{ 为 (3.12) 式右边部分.} \end{cases}$$

(2) 块SOR迭代法(BSOR)

选取分裂矩阵 M 为带松弛因子的 A 块下三角部分，即

$$\begin{cases} M = \dfrac{1}{\omega}(D - \omega L), \\ A = M - N. \end{cases}$$

得到块SOR迭代法

$$x^{(k+1)} = L_\omega x^{(k)} + f, \qquad (4.3)$$

其中迭代矩阵

$$L_\omega = I - \omega(D-\omega L)^{-1}A$$

$$= (D-\omega L)^{-1}((1-\omega)D+\omega U),$$

$$f = \omega(D-\omega L)^{-1}b,$$

由分块矩阵乘法得到块SOR迭代法的具体形式

$$\begin{cases} A_{ii}x_i^{(k+1)} = A_{ii}x_i^{(k)} + \omega\left(b_i - \sum_{j=1}^{i-1} A_{ij}x_j^{(k+1)} - \sum_{j=i}^{q} A_{ij}x_j^{(k)}\right) \\ (i=1,2,\cdots,q;\ \ k=0,1,\cdots), \\ \omega\text{为松弛因子.} \end{cases} \qquad (4.4)$$



于是，当 $x^{(k)}$ 及 $x_j^{(k+1)}\ (j=1,2,\cdots,i-1)$ 已计算时，解低阶方程组(3.14)可计算小块 $x_i^{(k+1)}$.

从 $x^{(k)} \to x^{(k+1)}$ 共需要解 q 个低阶方程组，当 A_{ii} 为三对角阵或带状矩阵时，可用直接法求解.

定理11 设 $Ax=b$，其中 $A=D-L-U$ (分块形式).

(1) 如果 A 为对称正定矩阵，

(2) $0<\omega<2$.

则解 $Ax=b$的BSOR迭代法收敛.

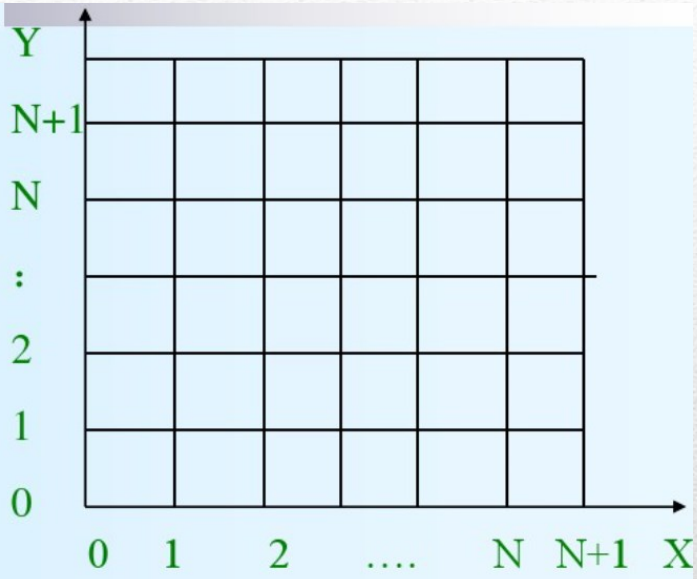
数值求解正方形域上的Poisson方程边值问题

$$\begin{cases} -\left(\dfrac{\partial^2 u}{\partial x^2}+\dfrac{\partial^2 u}{\partial y^2}\right)=f(x,y), 0<x,y<1 \\ u(0,y)=u(1,y)=u(x,0)=u(x,1)=0 \end{cases}$$

解:(1)剖分求解域.

$$x = x_i = ih, y = y_j = jh,$$

$$i, j = 0,1,...,N, N+1$$



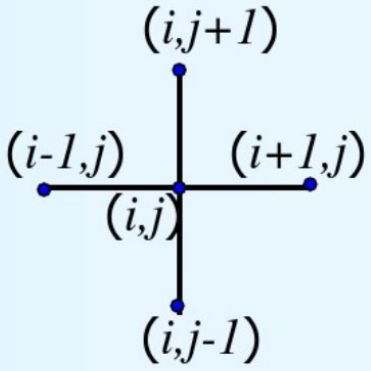
(2)对微分算子进行离散.

$$\frac{\partial^2 u}{\partial x^2}(x_i, y_j) = \frac{u(x_{i-1}, y_j) - 2u(x_i, y_j) + u(x_{i+1}, y_j)}{h^2} + O(h^2)$$

$$\frac{\partial^2 u}{\partial y^2}(x_i, y_j) = \frac{u(x_i, y_{j-1}) - 2u(x_i, y_j) + u(x_i, y_{j+1})}{h^2} + O(h^2)$$

$$\frac{\partial^2 u}{\partial x^2}(x_i, y_j) \approx \frac{u_{i-1,j} - 2u_{i,j} + u_{i+1,j}}{h^2}$$

$$\frac{\partial^2 u}{\partial y^2}(x_i, y_j) \approx \frac{u_{i,j-1} - 2u_{i,j} + u_{i,j+1}}{h^2}$$



在每个点(x_i,y_j)上的有限差分方程为

$$4u_{i,j} - u_{i-1,j} - u_{i+1,j} - u_{i,j-1} - u_{i,j+1} = h^2 f_{ij}$$

$$1 \le i, j \le N$$

又称为五点差分格式

在边界上

$$u_{0,j} = u_{N+1,j} = u_{i,0} = u_{i,N+1} = 0$$

对非边界点进行编号:

顺序为-----从下往上,从左往右

$$(x_1,y_1),(x_2,y_1),\ldots,(x_N,y_1),(x_1,y_2),(x_2,y_2),$$

$$\ldots,(x_N,y_2),\ldots,(x_1,y_N),(x_2,y_N),\ldots,(x_N,y_N)$$

相应的解向量和右端向量分别为

$$u=(u_{1,1},u_{2,1},\ldots,u_{N,1},u_{1,2},u_{2,2},\ldots,u_{N,2},\ldots,u_{1,N},$$

$$u_{2,N},\ldots,u_{N,N})^T$$

$$f=h^2(f_{1,1},f_{2,1},\ldots,f_{N,1},f_{1,2},f_{2,2},\ldots,f_{N,2},\ldots,f_{1,N},$$

$$f_{2,N},\ldots,f_{N,N})^T$$

差分方程组的矩阵形式为　Au=f

如果把每一条线上的网点看作一个组,如

$$v_1=(u_{1,1},u_{2,1},\ldots,u_{N,1})^T,$$

$$v_2=(u_{1,2},u_{2,2},\ldots,u_{N,2})^T,\ldots\ldots,$$

$$v_N=(u_{1,N},u_{2,N},\ldots,u_{N,N})^T$$

$$b_1=h^2(f_{1,1},f_{2,1},\ldots,f_{N,1})^T,$$

$$b_2=h^2(f_{1,2},f_{2,2},\ldots,f_{N,2})^T,\ldots$$

$$b_N=h^2(f_{1,N},f_{2,N},\ldots,f_{N,N})^T$$

$$A=\begin{pmatrix} A_{11} & -I & & \\ -I & A_{22} & \ddots & \\ & \ddots & \ddots & -I \\ & & -I & A_{NN} \end{pmatrix} \qquad u=\begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_N \end{pmatrix} \qquad f=\begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_N \end{pmatrix}$$

其中

$$A_{ii}=\begin{pmatrix} 4 & -1 & & \\ -1 & 4 & \ddots & \\ & \ddots & \ddots & -1 \\ & & -1 & 4 \end{pmatrix}$$

可用块迭代法

(即线迭代法)

求解Au=f

① 迭代法基本概念

② 雅可比与高斯-赛德尔迭代

③ 逐次超松弛法(SOR)

④ 共轭梯度法(CG)



- 共轭梯度法(Conjugate Gradient Method)，简称CG法
- 若无舍入误差，CG法经过n步计算，得到n阶线性方程组$Ax = b$的精确解
- 故CG法是解线性方程组的直接方法

等价问题

对 $AX=b$，设 A 为实对称正定阵，引入二次型

$$\varphi(w)=\frac{1}{2}(Aw,w)-(b,w),\ \forall w\in R^n$$

则，求解 $AX=b \Leftrightarrow$求一个向量$x^*\in R^n$，使得

$$\varphi(x^*)=\min_{w\in R^n}\varphi(w)$$

证明 设$x = A^{-1}b$为方程组的解向量，则有

$$\varphi(x) = \frac{1}{2}(Ax, x) - (b, x) = -\frac{1}{2}(Ax, x).$$

由此，对$\forall w \in R^n$，有

$$\begin{aligned}\varphi(w) - \varphi(x) &= \frac{1}{2}(Aw, w) - (b, w) + \frac{1}{2}(Ax, x) \\ &= \frac{1}{2}[(Aw, w) - 2(Ax, w) + (Ax, x)] \\ &= \frac{1}{2}(A(w - x), w - x) \\ &= \frac{1}{2}\|w - x\|_A^2 \geq 0,\end{aligned}$$

由A的正定性知，$w = x$为$\varphi(w)$的唯一极小值点。

反之，如果 $\bar{x}$ 使得$\varphi(x)$达到最小，则有$\varphi(\bar{x}) \leq \varphi(x)$对任意$x \in \mathbb{R}^n$成立，由上面证明有$\varphi(\bar{x}) - \varphi(x^*) = 0$, 即

$$\frac{1}{2}(A(\bar{x} - x^*), \bar{x} - x^*) = 0.$$

由A的正定性，可得 $\bar{x} = x^*$。

证毕

为求解极小问题，要通过某种规则构造出一个迭代向量序列$\{x^k\}$，使得函数值序列$\{\varphi(x^k)\}$单调递减，并收敛于$\varphi(x)$。其本质是如何给出从x^k到x^{k+1}的迭代格式。设该格式形如

$$x^{k+1} = x^k + \alpha_k q^k, k = 0,1,2,\cdots,$$

其中，$\alpha_k \in R$，而q^k表示从向量x^k到x^{k+1}的迭代方向。

α_k：迭代系数

q^k：迭代方向

最速下降法

由数学分析知识，一个多元函数沿其负梯度方向函数值下降得最快。因此，一种最自然的做法是将q^k取为$\varphi(x)$在x^k处的负梯度方向：$-\nabla\varphi(x^k)$。

记$r^k = b - Ax^k$为第k步迭代向量的残量，易知

$$r^k = -\nabla\varphi(x^k),$$

$$\begin{aligned} \varphi(x) &= \frac{1}{2}(Ax, x) - (b, x) \\ \varphi'(x) &= Ax - b \\ -\varphi'(x) &= b - Ax \end{aligned}$$

所以可以取 $q^k = r^k$

而取α_k，使得$\varphi(x^k + \alpha r^k), \alpha \in R$达到极小，

即 $\varphi(x^k + \alpha_k r^k) = \min_{\alpha \in R} \varphi(x^k + \alpha r^k).$

记$f(\alpha) = \varphi(x^k + \alpha r^k)$，则

$$\varphi(x) = \frac{1}{2}(Ax, x) - (b, x)$$

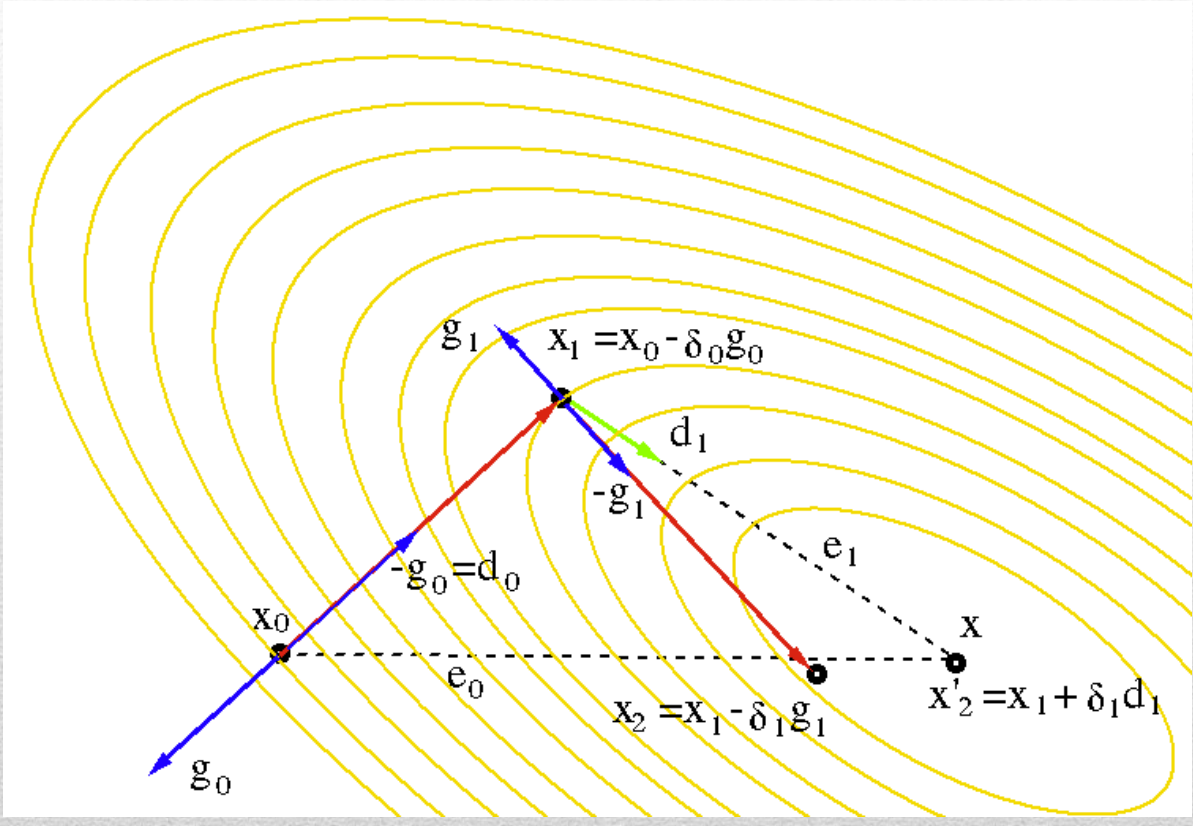
$$f(\alpha) = \frac{1}{2}(A(x^k + \alpha r^k), x^k + \alpha r^k) - (b, x^k + \alpha r^k)$$

$$= \varphi(x^k) - \alpha(r^k, r^k) + \frac{1}{2}\alpha^2(Ar^k, r^k),$$

由A的正定性可知，$f(\alpha)$的图像是一条开口向上的抛物线，故它存在唯一的极小点，其极小点为

$$\alpha_k = \frac{(r^k, r^k)}{(Ar^k, r^k)}$$

$$f'(\alpha) = \alpha(Ar^k, r^k) - (r^k, r^k)$$


g1
x1 =x0 - δ0g0
d1
-g1
e1
-g0 =d0
x0
x
e0
x2 =x1 - δ1g1
x'2 =x1 + δ1d1
g0

最速下降法的迭代格式

$$\begin{cases} \alpha_k = \dfrac{(r^k, r^k)}{(Ar^k, r^k)}, \\ x^{k+1} = x^k + \alpha_k r^k, & k = 0,1,2,\cdots, \\ r^{k+1} = b - Ax^{k+1}, \end{cases}$$

其中x^0为任意给定的初始迭代向量，$r^0 = b - Ax^0$.

设方程组为

$$\begin{bmatrix} 6 & 3 \\ 3 & 2 \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$

试用最速下降法解方程组，取$x^0 = (0,0)^{\mathrm{T}}$计算到x^4.

$k=1$	$x_0 = 0.0000,$	$x_1 = -0.5000$
$k=2$	$x_0 = 0.2500,$	$x_1 = -0.5000$
$k=3$	$x_0 = 0.2500,$	$x_1 = -0.8750$
$k=4$	$x_0 = 0.4375,$	$x_1 = -0.8750$
…	… …	
$k=71$	$x_0 = 1.0000,$	$x_1 = -1.9999$
$k=72$	$x_0 = 1.0000,$	$x_1 = -1.9999$
$k=73$	$x_0 = 1.0000,$	$x_1 = -2.0000$
$k=74$	$x_0 = 1.0000,$	$x_1 = -2.0000$

最速下降法的收敛性

定理 设A为对称正定矩阵，$x = A^{-1}b$，则对任意$x^0 \in R^n$，最速下降法收敛，且有

$$\left\| x^k - x \right\|_A \leq \left(\frac{cond_2(A) - 1}{cond_2(A) + 1} \right)^k \left\| x^0 - x \right\|_A$$

共轭梯度法

在最速下降法中，我们是将每一步的迭代方向q^k取为负梯度方向r^k，它只能保证局部下降最快，但从全局来看，这个方向并不一定最好

与最速下降法不同，CG 法的迭代方向p^k被选为A-共轭（或A-正交）的向量，即满足正交性质：

$$(p^i, p^j)_A := (Ap^i, p^j) = 0, \ \forall i \neq j,$$

共轭方向$\{p^k\}$和相应的迭代向量$\{x^k\}$的构造

1) 任意给定初始迭代向量x^0，计算初始残量

$r^0 = b - Ax^0$，取初始共轭方向$p^0 = r^0$

2) 对$k \geq 0$，令 $x^{k+1} = x^k + \alpha_k p^k$，其中$\alpha_k$满足

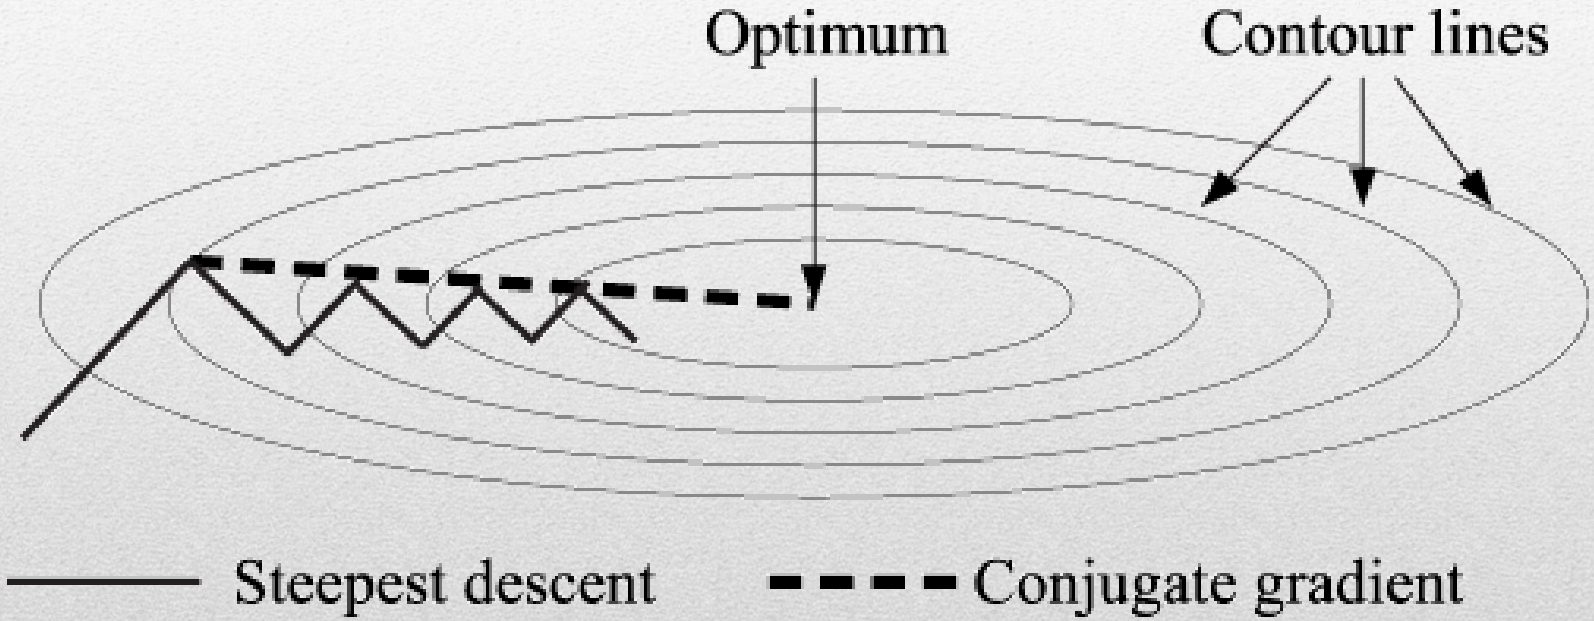
$$\varphi(x^{k+1}) = \min_{\alpha \in R} \varphi(x^k + \alpha p^k).$$

类似可推得 $\alpha_k = \dfrac{(r^k, p^k)}{(Ap^k, p^k)}$，$r^{k+1} = b - Ax^{k+1}$

3) 对$k \geq 0$, 令 $p^{k+1} = r^{k+1} + \beta_k p^k$.

利用p^k和p^{k+1}的A–共轭性，可求得待定系数

$$\beta_k = -\frac{(r^{k+1}, Ap^k)}{(Ap^k, p^k)}.$$


Optimum
Contour lines
Steepest descent
Conjugate gradient

综上，得到CG法的迭代格式

$$
\begin{cases}
\alpha_k := \dfrac{(r^k, p^k)}{(Ap^k, p^k)}, \\
x^{k+1} := x^k + \alpha_k p^k, \\
r^{k+1} := b - Ax^{k+1}, \quad k = 0,1,2,\cdots, \quad (**) \\
\beta_k := -\dfrac{(r^{k+1}, Ap^k)}{(Ap^k, p^k)}, \\
p^{k+1} = r^{k+1} + \beta_k p^k,
\end{cases}
$$

其中x^0为任意给定的初始迭代向量，

$$r^0 = b - Ax^0, \quad p^0 = r^0.$$

定理 由（**）式所得到的向量系$\{r^k\}$和$\{p^k\}$分别构成正交系和A-共轭系。

证明：用数学归纳法，我们有

$$\left(r^{(0)},r^{(1)}\right)=\left(r^{(0)},r^{(0)}\right)-\alpha_0\left(r^{(0)},Ar^{(0)}\right)=0,$$

$$\left(p^{1},Ap^{0}\right)=\left(r^{(1)},Ar^{(0)}\right)+\beta_0\left(r^{(0)},Ar^{(0)}\right)=0.$$

现设$r^{(0)},r^{(1)},\cdots,r^{(k)}$互相正交，$p^{(0)},p^{(1)},\cdots,p^{(k)}$相互共轭，则对$k+1$, 有

$$\left(r^{(k+1)},r^{(j)}\right)=\left(r^{(k)},r^{(j)}\right)-\alpha_k\left(Ap^{(k)},r^{(j)}\right).$$

- 若$j=k$，由α_k的表达式，可得$\left(r^{(k+1)},r^{(k)}\right)=0.$
- 若$j=0,1,\cdots,k-1$，由归纳假设，有$\left(r^{(k)},r^{(j)}\right)=0.$ 进而由$r^{(j)}=p^{(j)}-\beta_{j-1}p^{(j-1)}$，得

$$\left(r^{(k+1)},r^{(j)}\right)=-\alpha_k\left(Ap^{(k)},r^{(j)}\right)$$

$$=-\alpha_k\left(Ap^{(k)},p^{(j)}-\beta_{j-1}p^{(j-1)}\right)=0.$$

再看 $p^{(k+1)}$, 有

$$\left(p^{(k+1)}, Ap^{(k)}\right) = \left(r^{(k+1)}, Ap^{(k)}\right) + \beta_k \left(p^{(k)}, Ap^{(k)}\right) = 0,$$

对$j = 0,1,\cdots,k-1$, 有

$$\left(p^{(k+1)}, Ap^{(j)}\right) = \left(r^{(k+1)}, Ap^{(j)}\right) + \beta_k \left(p^{(k)}, Ap^{(j)}\right).$$

上式右端最后一项由归纳假设为零，其一项有

$$Ap^{(j)} = \frac{1}{\alpha_j}\left(r^{(j)} - r^{(j+1)}\right),$$

再由$r^{(k+1)}$与$r^{(j)}$的正交性，得$\left(r^{(k+1)}, Ap^{(j)}\right) = 0.$

证毕。

CG 法中α_k和β_k的计算公式可以进一步简化. 首先可得

$$\alpha_k = \frac{(r^k, p^k)}{(Ap^k, p^k)} = \frac{(r^k, r^k)}{(Ap^k, p^k)} .$$

$$\beta_k = -\frac{(r^{k+1}, Ap^k)}{(Ap^k, p^k)} = \frac{(r^{k+1}, r^{k+1})}{(r^k, r^k)}$$

注：在实际编程时，为了提高计算效率，常用以上两计算公式。

- 由定理　　，CG法最多迭代n次得到精确解
- 一方面，因舍入误差，n次迭代不一定得到精确解
- 另一方面，对大型方程组，n次迭代的工作量仍太大
- 实际上，通过比较当前残量r^k的范数和初始残量r^0的范数，来判断是否终止迭代

设方程组为

$$\begin{bmatrix} 6 & 3 \\ 3 & 2 \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$

试用共轭梯度法解方程组，取$x^0 = (0,0)^{\mathrm{T}}$.

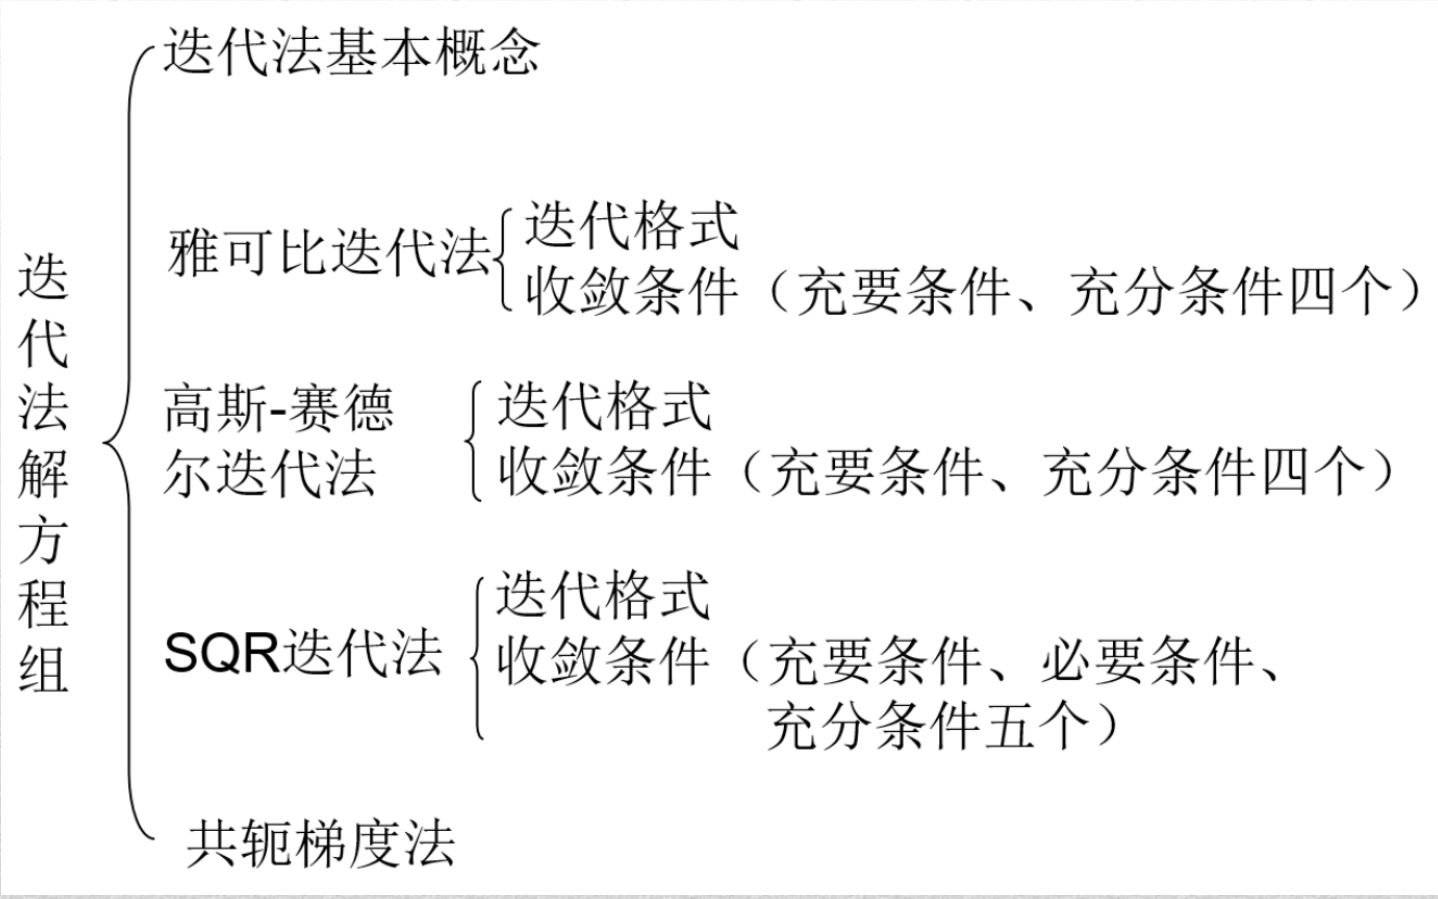
$k = 1$	$x_0 = 0.0000,$	$x_1 = -0.5000$
$k = 2$	$x_0 = 1.0000,$	$x_1 = -2.0000$

CG法的收敛性

定理 设A为对称正定矩阵，$x = A^{-1}b$，则用CG法求得的第k步迭代向量x^k有如下误差估计式

$$\left\| x - x^k \right\|_A \le 2\left(\frac{\sqrt{cond_2(A)} - 1}{\sqrt{cond_2(A)} + 1} \right)^k \left\| x - x^0 \right\|_A$$


中山大學
SUN YAT-SEN UNIVERSITY


迭代法解方程组
迭代法基本概念
雅可比迭代法
迭代格式
收敛条件（充要条件、充分条件四个）
高斯-赛德尔迭代法
迭代格式
收敛条件（充要条件、充分条件四个）
SQR迭代法
迭代格式
收敛条件（充要条件、必要条件、充分条件五个）
共轭梯度法